



Proyecto de Ciencia de Datos

Guía Avance 1: Formulación del Proyecto

El proyecto de la asignatura se desarrollará de manera **incremental**. Cada avance permitirá construir una parte del proyecto y recibir retroalimentación antes de continuar con la siguiente etapa.

El objetivo no es comenzar inmediatamente a entrenar modelos, sino desarrollar un proceso de Ciencia de Datos ordenado, donde exista una relación clara entre el **problema**, los **datos**, el **análisis** y las **conclusiones**.

1. Estructura general del proyecto

El proyecto estará dividido en cuatro instancias:

1. **Avance 1 – Formulación del proyecto y datos.**
Definición del problema, pregunta de análisis, motivación, identificación de variables, dataset y organización inicial del repositorio.
2. **Avance 2 – Análisis Exploratorio de Datos (EDA).**
Limpieza, transformación, análisis descriptivo, visualización e identificación de patrones relevantes para la pregunta planteada.
3. **Avance 3 – Modelado.**
Construcción, comparación y evaluación de modelos de Ciencia de Datos apropiados para responder la pregunta del proyecto.
4. **Presentación Final – Resultados y conclusiones.**
Integración del trabajo desarrollado durante el semestre y defensa de la respuesta obtenida para la pregunta original del proyecto.

Cada avance debe aprovechar y mejorar el trabajo realizado en la etapa anterior.

2. Objetivo del Avance 1

El propósito del primer avance es demostrar que el grupo posee un **problema de Ciencia de Datos claramente formulado** y que cuenta con datos que permiten comenzar a estudiarlo.

En esta etapa todavía **no es necesario realizar un análisis exploratorio completo ni entrenar modelos**.

Al finalizar el avance, debe quedar claro:

- qué problema se quiere estudiar;
- por qué el problema es interesante o relevante;
- qué pregunta concreta se intentará responder;
- cuáles son las variables disponibles;
- qué datos serán utilizados;
- cómo se organizará el trabajo dentro del repositorio GitHub.

3. La pregunta del proyecto: estructura X , Y y T

La pregunta del proyecto debe contener los tres elementos discutidos en clases:

- **X – Predictores:** variables o información disponible que será utilizada para estudiar el fenómeno.
- **Y – Objetivo:** variable, comportamiento o fenómeno que se desea explicar, estimar, predecir o caracterizar.



- **T – Contexto o ventana temporal:** periodo, horizonte o contexto temporal bajo el cual se plantea la pregunta.

Por ejemplo:

¿Es posible estimar la demanda diaria de bicicletas públicas (Y) utilizando información meteorológica, calendario y demanda histórica (X), para anticipar la demanda del día siguiente (T)?

Otro ejemplo podría ser:

¿Qué variables asociadas al comportamiento de compra de un cliente (X) permiten estimar su gasto mensual (Y) durante los próximos tres meses (T)?

La pregunta puede cambiar durante el desarrollo del proyecto si el análisis de los datos demuestra que es necesario ajustar su alcance. Sin embargo, para este avance debe existir una **primera versión concreta y evaluables**.

4. Presentación del Avance 1

Cada grupo deberá realizar una presentación breve de **máximo 5–6 diapositivas**.

La presentación debe permitir comprender el proyecto rápidamente y no debe convertirse en una revisión extensa del tema.

Una estructura sugerida es:

Diapositiva 1 – Proyecto y problema

- Nombre del proyecto.
- Integrantes.
- Problema general que se desea estudiar.
- Contexto donde aparece el problema.

Diapositiva 2 – Motivación

Explicar brevemente:

- ¿Por qué es interesante estudiar este problema?
- ¿Quién podría beneficiarse de los resultados?
- ¿Qué decisión, fenómeno o comportamiento se desea comprender?

No se espera una revisión bibliográfica extensa. La motivación debe ser **concreta y directamente relacionada con el proyecto**.

Diapositiva 3 – Pregunta de Ciencia de Datos

Presentar explícitamente la pregunta del proyecto.

Además, identificar:

X = Predictores	Y = Objetivo	T = Contexto temporal
-------------------	----------------	-------------------------

Debe existir coherencia entre estos tres elementos y los datos disponibles.



Diapositiva 4 – Dataset

Presentar el dataset seleccionado.

Como mínimo indicar:

- fuente de los datos;
- número aproximado de registros;
- número y tipo de variables;
- variable objetivo, si ya está identificada;
- variables predictoras principales;
- rango o cobertura temporal;
- unidad de observación.

Se recomienda mostrar una pequeña tabla con algunas filas o un esquema de las variables principales.

Diapositiva 5 – Relación entre pregunta y datos

Explicar brevemente cómo los datos permiten abordar la pregunta propuesta.

Por ejemplo:

- qué columnas corresponden a X ;
- qué columna o indicador corresponde a Y ;
- cómo se representa T ;
- qué información adicional podría ser necesaria.

Esta diapositiva busca comprobar que la pregunta propuesta **realmente puede ser estudiada con el dataset seleccionado**.

Diapositiva 6 – Organización del proyecto

Mostrar el repositorio GitHub y su estructura inicial.

Por ejemplo:

```
proyecto-ciencia-datos/  
|  
|-- data/  
|   |-- raw/  
|   '-- processed/  
|  
|-- notebooks/  
|   '-- 01_exploracion.ipynb  
|  
|-- src/  
|  
|-- figures/  
|  
'-- README.md
```

No se espera que estas carpetas contengan todavía el proyecto terminado. Se evaluará principalmente que exista una estructura que permita **organizar y reproducir el trabajo durante el semestre**.



5. Qué NO se espera todavía

En el Avance 1 no es necesario presentar:

- modelos de Machine Learning;
- métricas de desempeño;
- tuning de hiperparámetros;
- un EDA completo;
- dashboards;
- conclusiones definitivas.

Estos elementos serán desarrollados progresivamente en los siguientes avances.
El foco de esta presentación es:

Problema → Pregunta → Datos → Plan de trabajo



6. Rúbrica de Evaluación – Avance 1

La evaluación se realizará principalmente durante la presentación del grupo.

Criterio	Descripción	Puntaje
1. Problema y motivación	El problema está claramente explicado y existe una motivación concreta para estudiarlo. Se identifica el contexto y la relevancia del proyecto.	15
2. Pregunta de Ciencia de Datos	La pregunta es específica, comprensible y susceptible de ser abordada mediante análisis de datos.	20
3. Definición de X , Y y T	Se identifican claramente los predictores (X), el objetivo (Y) y el contexto o ventana temporal (T). Los tres elementos son coherentes con la pregunta planteada.	20
4. Dataset	Se identifica la fuente de datos y se describen adecuadamente su tamaño, variables, unidad de observación y cobertura temporal.	20
5. Coherencia pregunta-datos	El grupo demuestra que las variables disponibles permiten abordar razonablemente la pregunta propuesta y reconoce posibles limitaciones de los datos.	10
6. Organización en GitHub	El repositorio existe y presenta una estructura inicial ordenada para datos, notebooks, código y documentación.	10
7. Presentación	La presentación es clara, sintética y respetuosa del máximo de 5–6 diapositivas. El grupo explica el proyecto sin depender exclusivamente del texto de las diapositivas.	5
Total		100

7. Aspectos que se revisarán durante la presentación

Durante la presentación el profesor podrá realizar preguntas como:

- ¿Cuál es exactamente la unidad de observación del dataset?
- ¿Qué variable quieren explicar o predecir?
- ¿Qué información estará disponible al momento de realizar la predicción?
- ¿Dónde aparece la dimensión temporal del problema?
- ¿El dataset contiene realmente las variables necesarias para responder la pregunta?
- ¿Existen problemas evidentes de datos faltantes, desbalance, cobertura temporal o calidad de los datos?
- ¿Cómo piensan organizar el desarrollo del proyecto en GitHub?

No es necesario tener todas estas respuestas completamente resueltas. Estas preguntas tienen como objetivo ayudar a **delimitar correctamente el proyecto antes del Avance 2**.

8. Resultado esperado

Al finalizar el Avance 1, cada grupo debería contar con:

- una pregunta de Ciencia de Datos claramente formulada;
- una definición preliminar de X , Y y T ;
- un dataset identificado y descargado;
- una comprensión inicial de sus principales variables;



- un repositorio GitHub organizado;
- un alcance de proyecto suficientemente acotado para comenzar el análisis exploratorio.

Este avance constituye el punto de partida para el **Avance 2: Análisis Exploratorio de Datos (EDA)**.